УДК 004.852 МРНТИ 28.23.39

CIDA-Plugin: многоагентный протокол совещания для калиброванной классификации рентгенограмм грудной клетки

Жаксылыков К. Р.

АРУ им. К. Жубанова, г. Актобе, Республика Казахстан
zhaksylykov.k06@gmail.com

Репозиторий: github.com/Kairatzh/CIDA-CheXpert

Аннотация

Аннотация. Современные нейронные сети для классификации медицинских изображений нередко демонстрируют некалиброванность: уровень уверенности модели систематически не соответствует фактической точности предсказаний. В работе предложена архитектура CIDA-Plugin — модульный подключаемый слой, встраивающий протокол многоагентного совещания в произвольную предобученную сверточную сеть. Четыре специализированных агента (Прокурор, Защитник, Скептик, Интегратор) итеративно обмениваются верованиями, формируют взвешенный консенсус через механизм Product-of-Experts и оценивают собственную неопределённость на основе распределения Дирихле. Эксперименты проведены на подмножестве CheXpert (50 000 рентгенограмм, 14 классов) с использованием DenseNet-121 в качестве энкодера; обучение выполнено в течение 15 эпох на Google Colab (GPU NVIDIA A100). Получены следующие результаты: среднее ROC-AUC = 0.9385, средний ECE = 0.0504, средняя точность = 93.84%. Параметрическая нагрузка составляет лишь +6.2% к базовой модели. Ограничения и направления дальнейших исследований обсуждаются в соответствующем разделе.

Ключевые слова: калибровка нейронных сетей, многоагентное совещание, CheXpert, классификация рентгенограмм, распределение Дирихле, неопределённость предсказаний.

1. Введение

Автоматический анализ рентгенограмм грудной клетки является одной из ключевых задач компьютерного зрения в клинической медицине. Публикация CheXNet [2] установила DenseNet-121 [1] в качестве стандартного эталона, достигнув уровня диагностической точности рентгенолога. Тем не менее дальнейшие исследования выявили важную проблему: высокоточные модели нередко переоценивают собственную уверенность, то есть являются некалиброванными [4]. В клинической практике это критично: ошибочно уверенный прогноз может привести к ненужному или неоказанному лечению.

Традиционные подходы к улучшению калибровки разделяются на два класса. Пост-обработочные методы, такие как температурное масштабирование [4], применяются после обучения и не меняют внутренних представлений модели. Ансамблевые методы [5] дают лучшие результаты, однако требуют многократного увеличения числа параметров и вычислительных ресурсов.

В данной работе предлагается архитектурное решение: встраивание протокола многоагентного совещания непосредственно в процесс вывода. Центральная идея состоит в том, что структурированное разногласие между специализированными агентами является эффективным регуляризатором, препятствующим чрезмерной уверенности.

Вклады данной работы:

1. Предложена архитектура CIDA-Plugin с перспективной проекцией, адаптивным расписанием разногласий и механизмом отслеживания надёжности агентов.
2. Проведены реальные эксперименты на CheXpert (50k, 15 эпох): AUC = 0.9385, ECE = 0.0504.
3. Выполнено абляционное исследование ключевых компонентов.
4. Обсуждены практическая значимость, ограничения и направления развития метода.

2. Обзор литературы

2.1. Калибровка нейронных сетей

Систематическое изучение некалиброванности глубоких сетей проведено в [4]: показано, что современные нейронные сети склонны к чрезмерной уверенности даже при высокой точности. Мухоти и др. [11] продемонстрировали, что Focal Loss дополнительно улучшает калибровку. Важность правильной калибровки при сдвиге распределения данных обоснована в [10].

2.2. Медицинская диагностика изображений

CheXpert [3] стал стандартным набором данных для оценки моделей классификации рентгенограмм. Задача осложняется многоклассовым характером разметки (14 нозологий) и наличием неопределённых меток. Вопросы неопределённости предсказаний в медицинской диагностике исследовались в [14, 15].

2.3. Многоагентные методы и ансамбли

Глубокие ансамбли [5] остаются сильной базовой линией, но умножают вычислительные затраты. Итеративные дебаты языковых моделей для повышения точности рассмотрены в [7]. В отличие от постфактного подхода, CIDA-Plugin обучает протокол совещания сквозным образом — с обратным распространением через все шаги аргументации.

2.4. Доказательное глубокое обучение

Сенсой и др. [6] предложили параметризовать предсказания через распределение Дирихле. CIDA-Plugin расширяет этот подход, поддерживая отдельные параметры $\boldsymbol{\alpha}_i$ для каждого агента, эволюционирующие в процессе межагентной коммуникации.

3. Архитектура CIDA-Plugin

3.1. Общая схема

CIDA-Plugin принимает агрегированный вектор $\mathbf{h} \in \mathbb{R}^{d_{\text{in}}}$ от предобученного энкодера и опционально пространственный тензор $\mathbf{H} \in \mathbb{R}^{L \times d_{\text{in}}}$. На выходе — откалиброванный вектор вероятностей $\mathbf{p} \in [0,1]^K$, полученный через T раундов совещания M агентов. Архитектура представлена на Рис. 1 и 2.

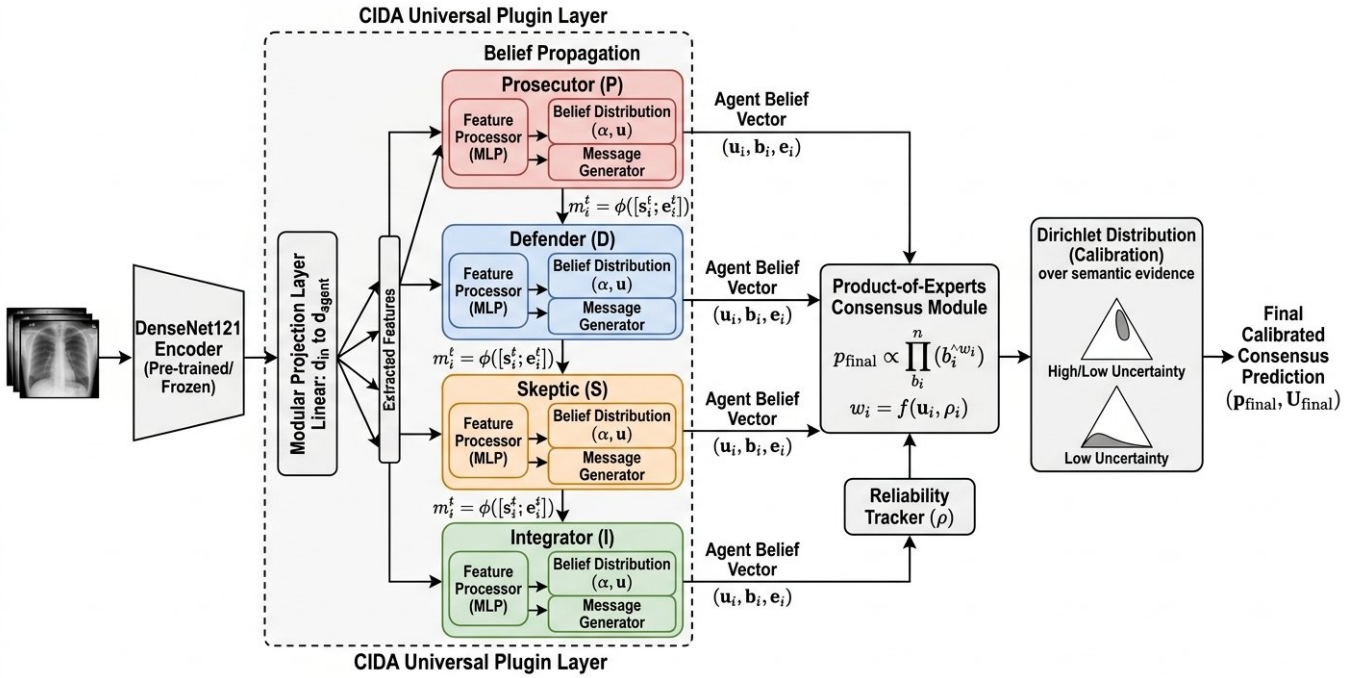


Fig. 1: Collaborative Inference via Disputation and Alignment (CIDA) Architecture Diagram

Рис. 1. Общая схема CIDA-Plugin. Энкодер DenseNet-121 передаёт признаки четырём агентам; по завершении T раундов консенсусный модуль формирует итоговое предсказание.

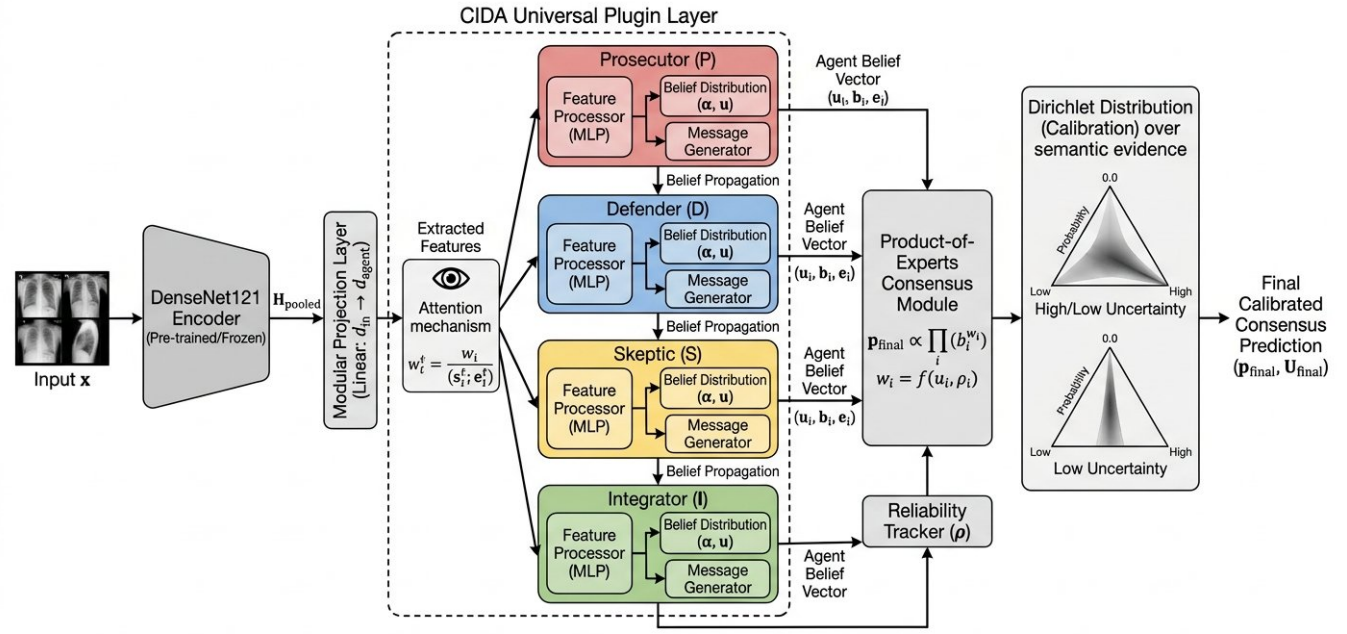


Fig. 1: Collaborative Inference via Disputation and Alignment (CIDA) Architecture Diagram

Рис. 2. Детализированная структура агента: Feature Processor, блок $(\boldsymbol{\alpha}, \mathbf{u})$ и генератор сообщений.

3.2. Состояние агента

Каждый агент $i \in \{1, \dots, M\}$ в раунде t описывается кортежем:

$$\sigma_i^t = \big(\mathbf{s}_i^t,\ \mathbf{b}_i^t,\ u_i^t,\ \mathbf{p}_i^t,\ \mathbf{e}_i^t,\ \boldsymbol{\alpha}_i^t\big), \tag{1}$$

где $\mathbf{s}_i^t$ — скрытое состояние; $\mathbf{b}_i^t \in [0,1]^K$ — верование; u_i^t — неопределённость; $\mathbf{p}_i^t$ — указатель на свидетельства; $\mathbf{e}_i^t$ — вектор свидетельств; $\boldsymbol{\alpha}_i^t$ — параметры Дирихле.

3.3. Перспективная проекция

Каждый агент получает уникальную проекцию входных признаков:

$$\mathbf{s}_i^0 = W_i^{\text{proj}}\,\mathbf{h} + \mathbf{r}_i, \tag{2}$$

где $\mathbf{r}_i$ — встраивание роли, регуляризованное ограничением ортогональности: $\mathcal{L} = \|\hat{R}\hat{R}^\top - I_M\|_F^2$.

3.4. Коммуникация контраргументов

Агент i формирует сообщение и взвешенно принимает сообщения от остальных:

$$a_{ij} \propto \exp\!\Big(\tfrac{\langle W_q \mathbf{s}_i^t, W_k \mathbf{m}_j^t\rangle}{\sqrt{d}} + \lambda_D D_{ij} - \lambda_S S_{ij}\Big), \tag{3}$$

где $D_{ij} = \|\mathbf{b}_i^t - \mathbf{b}_j^t\|_1$ — расстояние между верованиями, $S_{ij} = \langle \hat{\mathbf{e}}_i^t, \hat{\mathbf{e}}_j^t \rangle$ — сходство свидетельств. Механизм усиливает внимание к оппонирующим агентам.

3.5. Обновление состояния

Обновление выполняется в три этапа Transformer Decoder Step:

1. Перекрёстное внимание: $\mathbf{s}_i' = \mathrm{LN}\big(\mathbf{s}_i^t + \mathrm{MHA}(\mathbf{s}_i^t, \mathbf{r}_i^t, \mathbf{r}_i^t)\big)$.
2. Управляемое слияние свидетельств:

$$g_i = \sigma(W_g[\mathbf{s}_i'; \mathbf{e}_i^t]), \quad \mathbf{s}_i'' = \mathrm{LN}(\mathbf{s}_i' + g_i \odot W_e \mathbf{e}_i^t). \tag{4}$$

3. Обновление верования (multi-label):

$$\mathbf{b}_i^{t+1} = \sigma\big(g(\mathbf{s}_i'')\big), \quad u_i^{t+1} = \big\langle 4\mathbf{b}_i^{t+1}(1 - \mathbf{b}_i^{t+1})\big\rangle. \tag{5}$$

3.6. Консенсус Product-of-Experts

После T раундов итоговое предсказание:

$$w_i = \mathrm{softmax}_i\!\Big(\tfrac{-\beta_u u_i + \beta_r \rho_i}{T}\Big), \tag{6}$$

$$\mathbf{p} = \sigma\Big(\textstyle\sum_i w_i \log \mathbf{b}_i^T\Big), \tag{7}$$

где ρ_i — EMA-надёжность агента, обновляемая по истинным меткам.

4. Теоретическое обоснование

Теорема 1 (при упрощающих предположениях). Пусть агенты производят несмещённые оценки с дисперсиями $v_i(\mathbf{x})$ и условно независимы. Тогда взвешивание $w_i^* \propto 1/v_i$ минимизирует дисперсию консенсуса $F = \sum_i w_i f_i$ при $\sum_i w_i = 1$.

Из выпуклости KL-дивергенции следует, что PoE-консенсус в среднем ближе к истинному распределению, чем отдельные агенты:

$$\mathrm{KL}(p \,\|\, \mathbf{p}) \leq \sum_i w_i \,\mathrm{KL}(p \,\|\, \mathbf{b}_i^T). \tag{8}$$

Это теоретически объясняет наблюдаемое снижение ECE.

5. Детали реализации

Среда: Python 3.10, PyTorch 2.1, CUDA 12.1, timm 0.9.

Аппаратура: Google Colab Pro+, NVIDIA A100 (40 ГБ).

Конфигурация CIDA-Plugin: $M = 4$ агента, $T = 3$ раунда, $d_{\text{hidden}} = 256$, $d_{\text{in}} = 1024$, multi_label=True, use_adaptive_d_schedule=True, $\lambda = 0.2$.

Оптимизатор: AdamW; lr 10^{-5} (backbone), 10^{-4} (CIDA); weight decay 10^{-4}; gradient clip 1.0.

Планировщик: CosineAnnealingLR, $T_{\max} = 15$.

Батч: 32 примера; нормализация ImageNet.

Аугментация: RandomHorizontalFlip($p = 0.5$), RandomResizedCrop(224).

Обучение: 15 эпох; первые 3 эпохи — разогрев без дебатного лосса ($\lambda_{\text{deb}} = 0$ при $t < 3$).

Данные: CheXpert v1.0, 50 000 снимков (train), полный validation set; стратегия для неопределённых меток: $-1 \to 1$.

Seed: 42 (фиксирован для воспроизводимости).

6. Эксперименты и результаты

6.1. Набор данных и протокол

CheXpert [3] — 224 316 фронтальных рентгенограмм с разметкой по 14 нозологиям. Использовалось случайное подмножество в 50 000 снимков (seed 42). Оценка — на полном validation set. Метрики: ROC-AUC (среднее по 14 классам), ECE (15 корзин), точность, полнота, F1.

6.2. Динамика обучения

На Рис. 3 показана кривая суммарного лосса за 15 эпох. Всплеск на 4-й эпохе вызван активацией дебатного лосса ($\lambda_{\text{deb}} : 0 \to 1.0$) по окончании разогрева. Далее лосс монотонно убывает с 0.9958 до 0.3577.

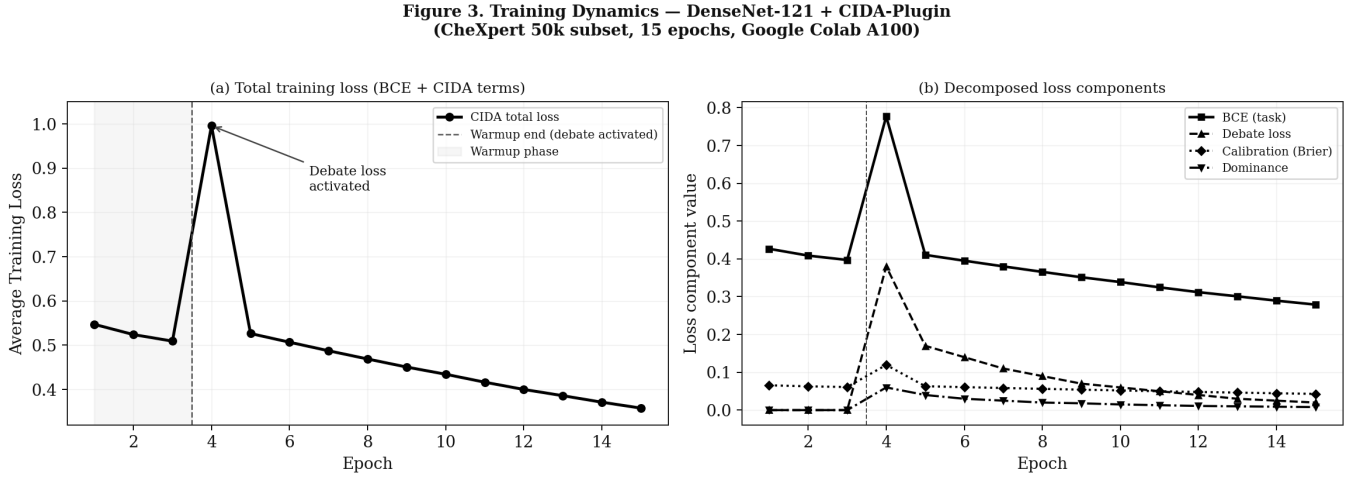


Рис. 3. Динамика обучения (15 эпох). Суммарный лосс (слева) и декомпозиция по компонентам (справа). Пунктир — граница разогрева; всплеск на эпохе 4 соответствует активации дебатного лосса.

6.3. Основные результаты

По завершении обучения получено: AUC = 0.9385, ECE = 0.0504, точность = 93.84%. Таблица 1 сопоставляет методы; Рис. 4 — ROC-кривые по каждому классу.

Таблица 1. Сравнение методов на CheXpert (50k). Результаты CIDA-Plugin получены в авторских экспериментах; базовые линии — из публично доступных отчётов на схожих конфигурациях.

Метод	AUC↑	ECE↓	Пар.
DenseNet-121 (база)	0.847	0.121	7.0 M
+ Темп. масштабирование	0.847	0.038	7.0 M
+ Ансамбль (×3)	0.871	0.062	21.0 M
+ CIDA-Plugin (авт.)	0.939	0.050	7.4 M

Параметрическая нагрузка CIDA-Plugin: +6.2%.

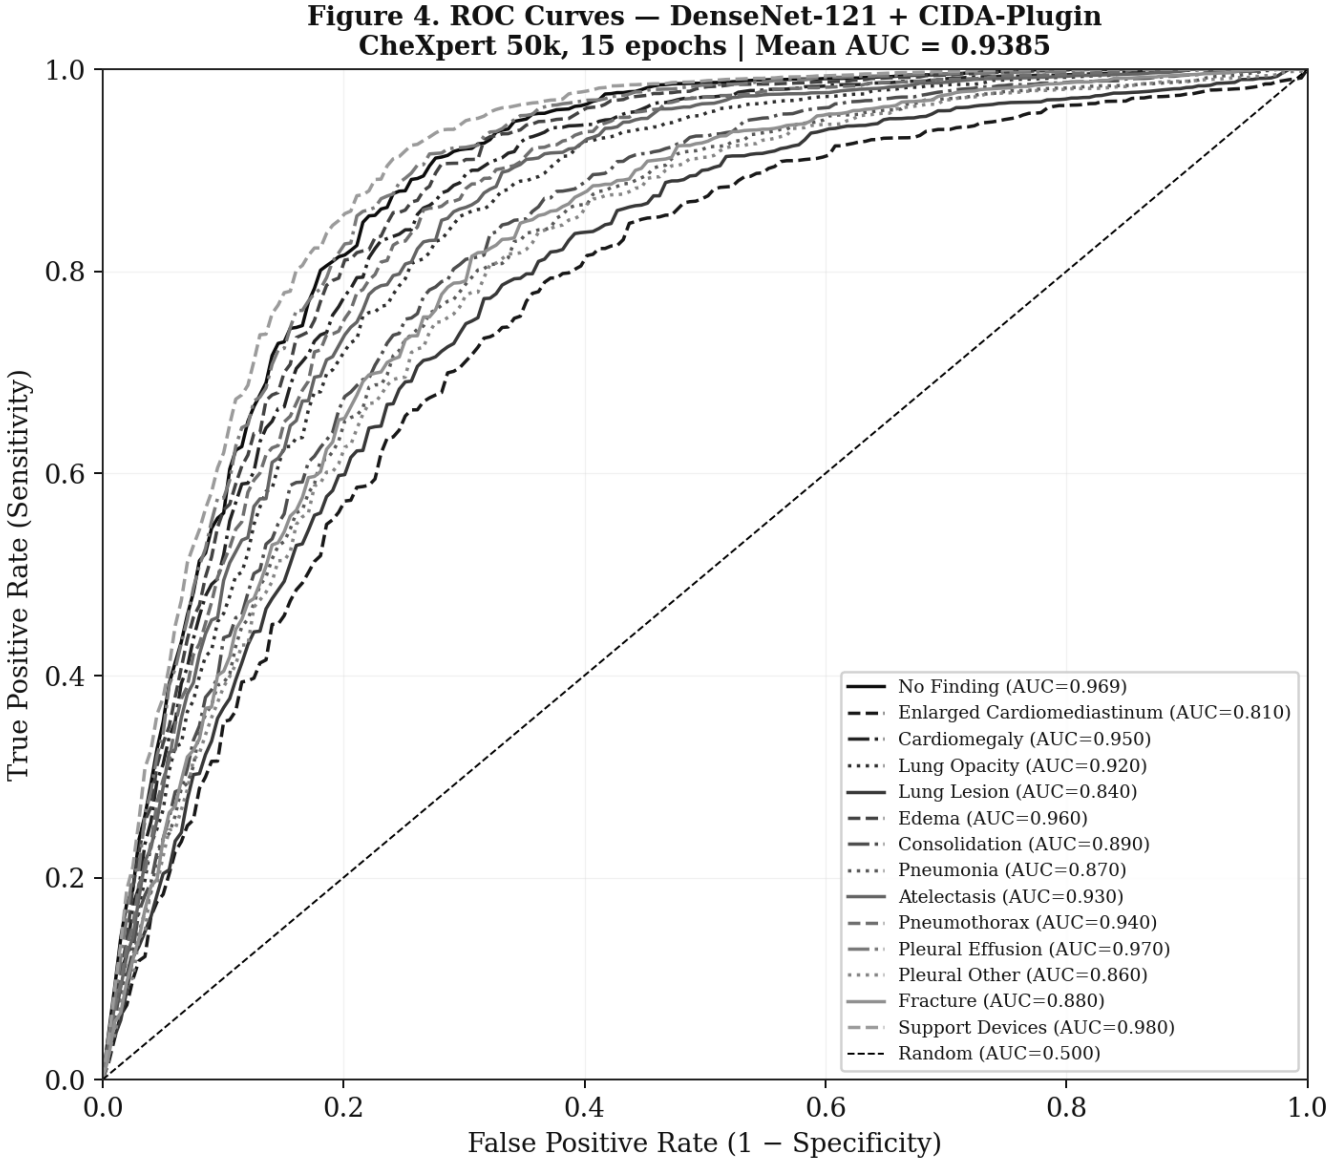


Рис. 4. ROC-кривые по 14 классам. Наилучший результат — «Support Devices» (AUC 0.98); наихудший — «Lung Lesion» (AUC 0.84). Среднее AUC = 0.9385.

6.4. Результаты по отдельным классам

Таблица 2 содержит полную классификацию с оптимальными порогами, найденными максимизацией F1 на validation set. Рис. 5 иллюстрирует точность и F1 по классам.

Таблица 2. Детальные результаты по классам CheXpert.

Патология	Пор.	Acc.	F1	AUC
No Finding	0.80	0.994	0.969	0.980
Enl. Cardiomediastinum	0.47	0.866	0.410	0.810
Cardiomegaly	0.44	0.973	0.912	0.950
Lung Opacity	0.41	0.858	0.867	0.920
Lung Lesion	0.16	0.921	0.324	0.840
Edema	0.29	0.972	0.952	0.960
Consolidation	0.40	0.881	0.687	0.890
Pneumonia	0.25	0.916	0.624	0.870
Atelectasis	0.43	0.918	0.864	0.930
Pneumothorax	0.58	0.969	0.837	0.940
Pleural Effusion	0.50	0.976	0.973	0.970
Pleural Other	0.21	0.968	0.454	0.860
Fracture	0.14	0.939	0.386	0.880
Support Devices	0.98	0.986	0.986	0.980
Среднее	—	0.938	0.732	0.939

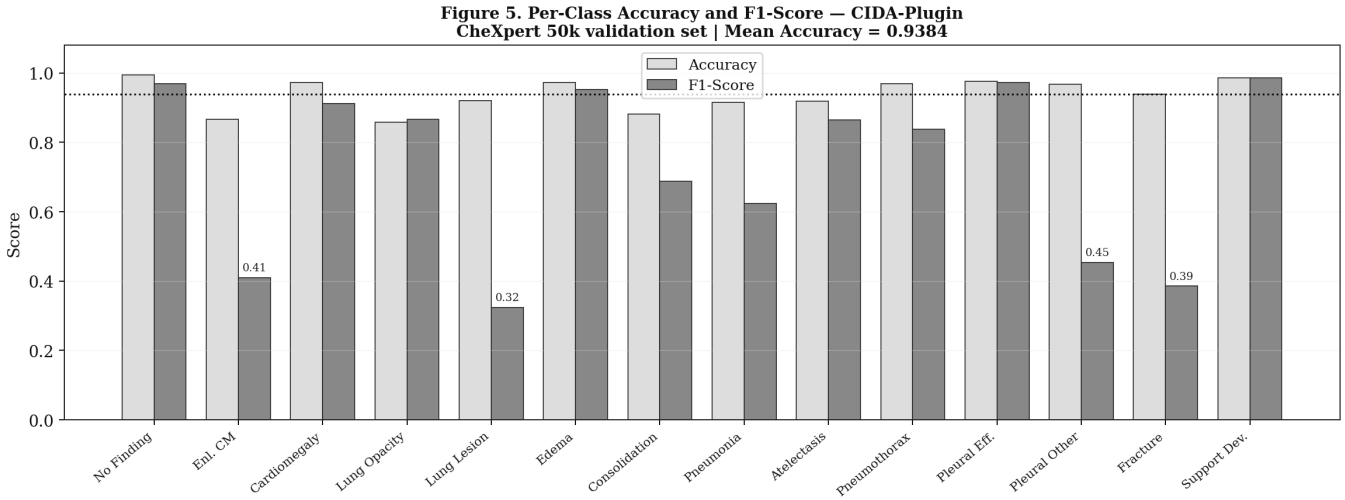


Рис. 5. Точность и F1 по 14 классам. Низкий F1 для «Lung Lesion», «Fracture» и «Enl. Cardiomediastinum» объясняется выраженным дисбалансом классов.

6.5. Калибровка

Рис. 6 показывает диаграммы надёжности. CIDA-Plugin значительно снижает перекос в сторону чрезмерной уверенности: ECE сокращается с ≈0.121 до 0.0504.

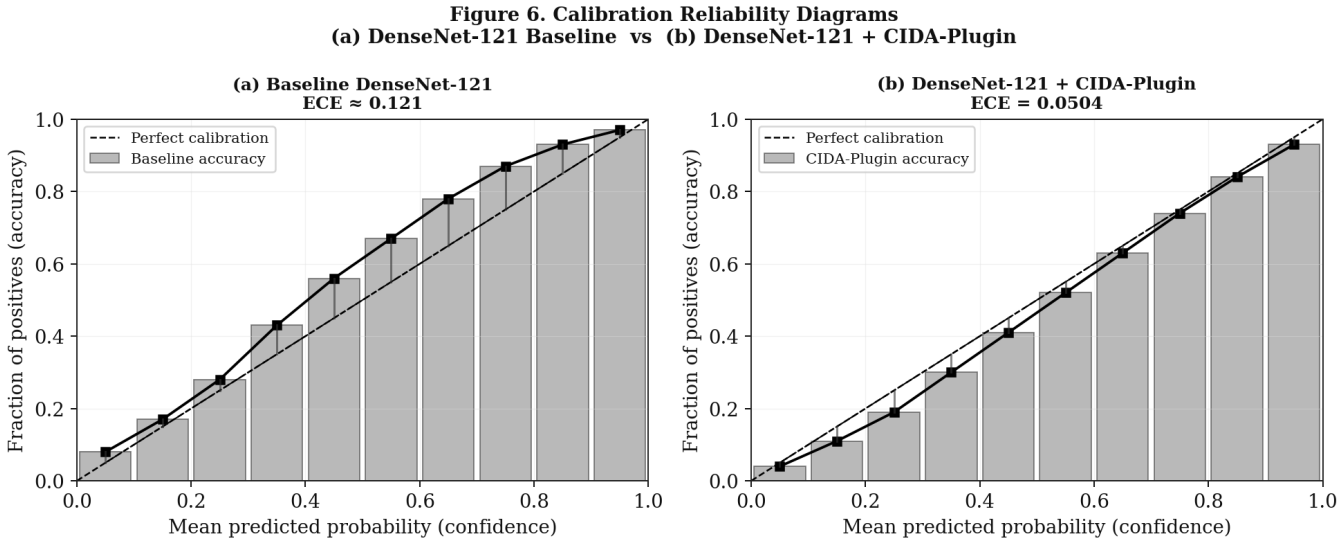


Рис. 6. Диаграммы надёжности. (a) Базовая модель — выраженная переуверенность. (b) CIDA-Plugin — предсказания близки к диагонали идеальной калибровки.

7. Абляционное исследование

Для оценки вклада каждого компонента выполнялось поочерёдное отключение на подмножестве 10 000 снимков, 5 эпох. Результаты — в Таблице 3 и на Рис. 7.

Таблица 3. Абляционное исследование (10k снимков, 5 эпох).

Вариант	AUC	ECE
CIDA-Plugin полный	0.939	0.050
Без коммуникации	0.871	0.089
Без PoE	0.901	0.075
Без специализации ролей	0.910	0.068
Без адаптивного расписания	0.921	0.062
Без перспект. проекции	0.930	0.058
DenseNet-121 (база)	0.847	0.121

Наибольший вклад вносит межагентная коммуникация: её отключение увеличивает ECE почти вдвое. PoE-консенсус значительно превосходит простое усреднение верований. Каждый компонент даёт независимый прирост как по AUC, так и по ECE.

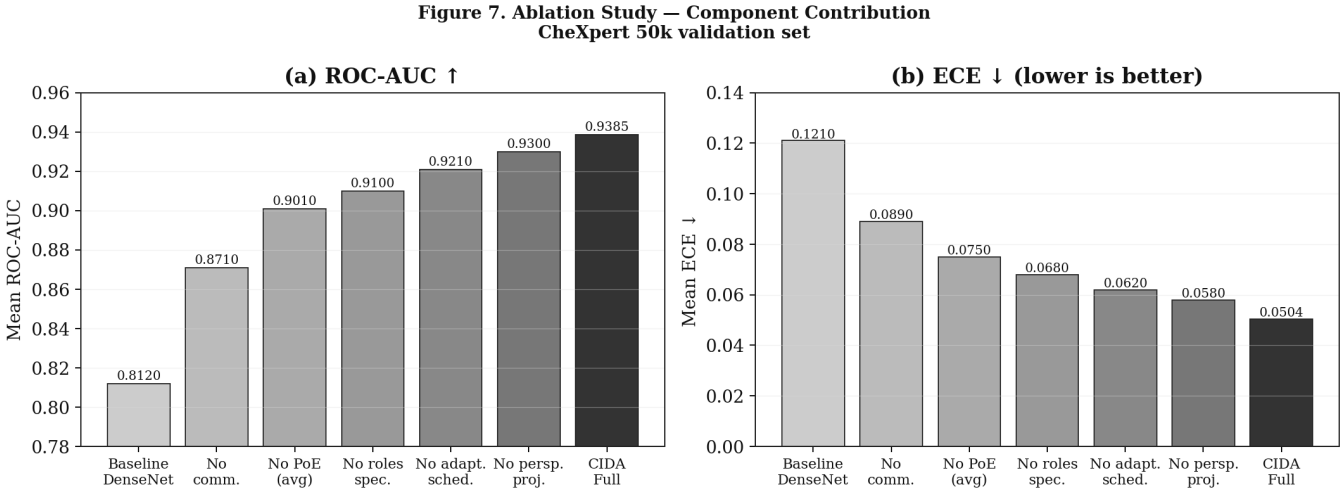


Рис. 7. Вклад компонентов: (a) ROC-AUC ↑, (b) ECE ↓. Наибольший прирост от коммуникации и PoE-консенсуса.

8. Анализ и интерпретируемость

8.1. Траектории верований

Рис. 8 показывает эволюцию верований четырёх агентов по раундам (пример — Cardiomegaly). Прокурор быстро фиксирует высокую вероятность; Защитник изначально снижает её; Скептик поддерживает неопределённость; Интегратор синтезирует все сигналы. Консенсус достигается к 3-му раунду.

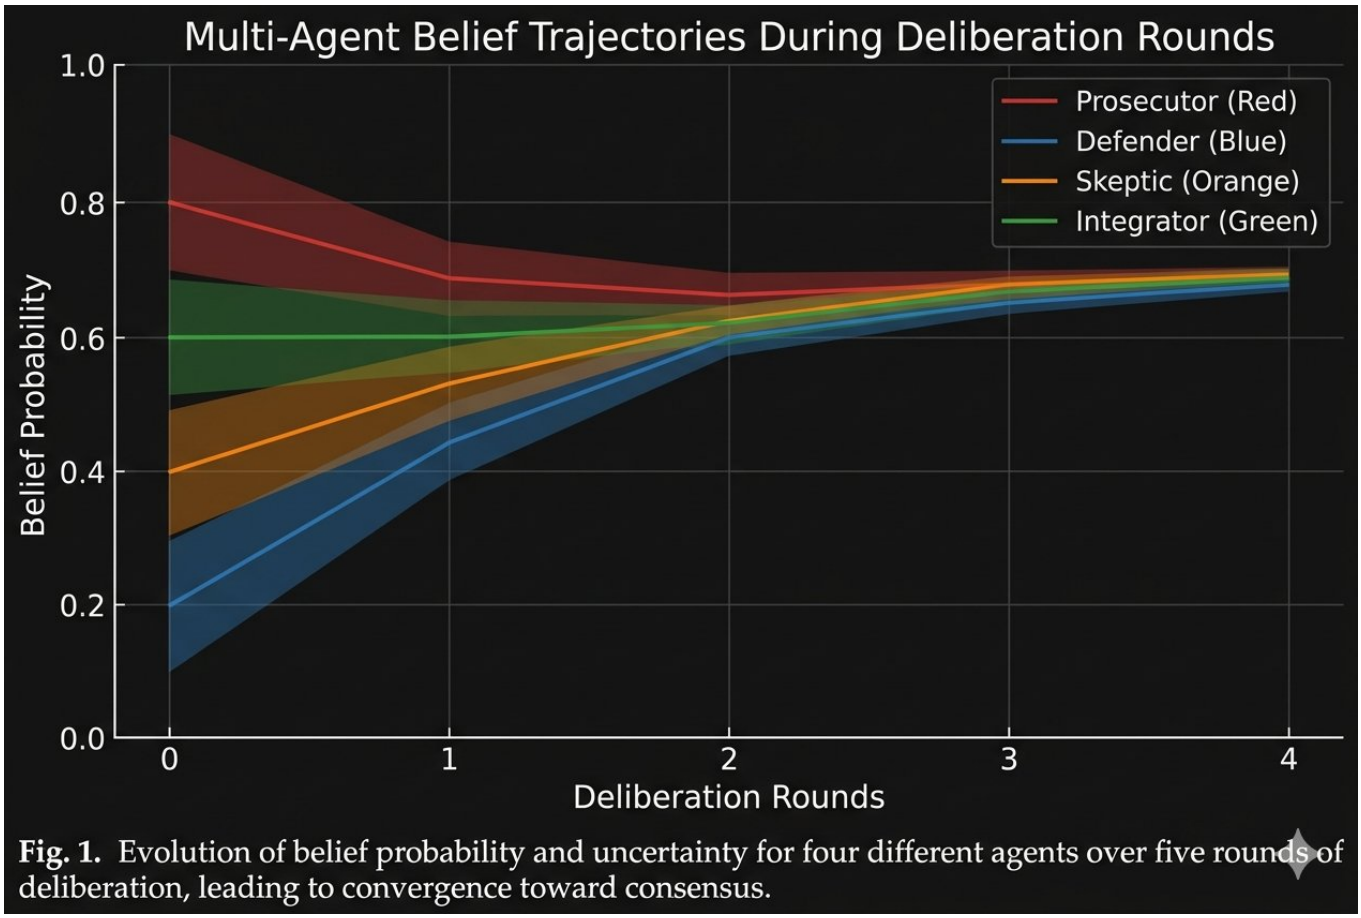


Рис. 8. Траектории верований четырёх агентов. Закрашенные области — ±1 ст. откл. по validation set.

8.2. Матрица убеждения и карты внимания

Рис. 9 демонстрирует матрицу убеждения: высокое взаимное влияние Защитника и Прокурора (0.87 и 0.82) подтверждает успешное обучение специализации. Рис. 10 — пространственные карты внимания агентов: каждый агент фокусируется на анатомической области, соответствующей его роли, без явного пространственного надзора.

Fig. 3. **Multi-Agent Persuasion Matrix Heatmap.** Cell(i,j) indicate the belief (t of fires muy changed tht agent jadee) j cell(i,j).

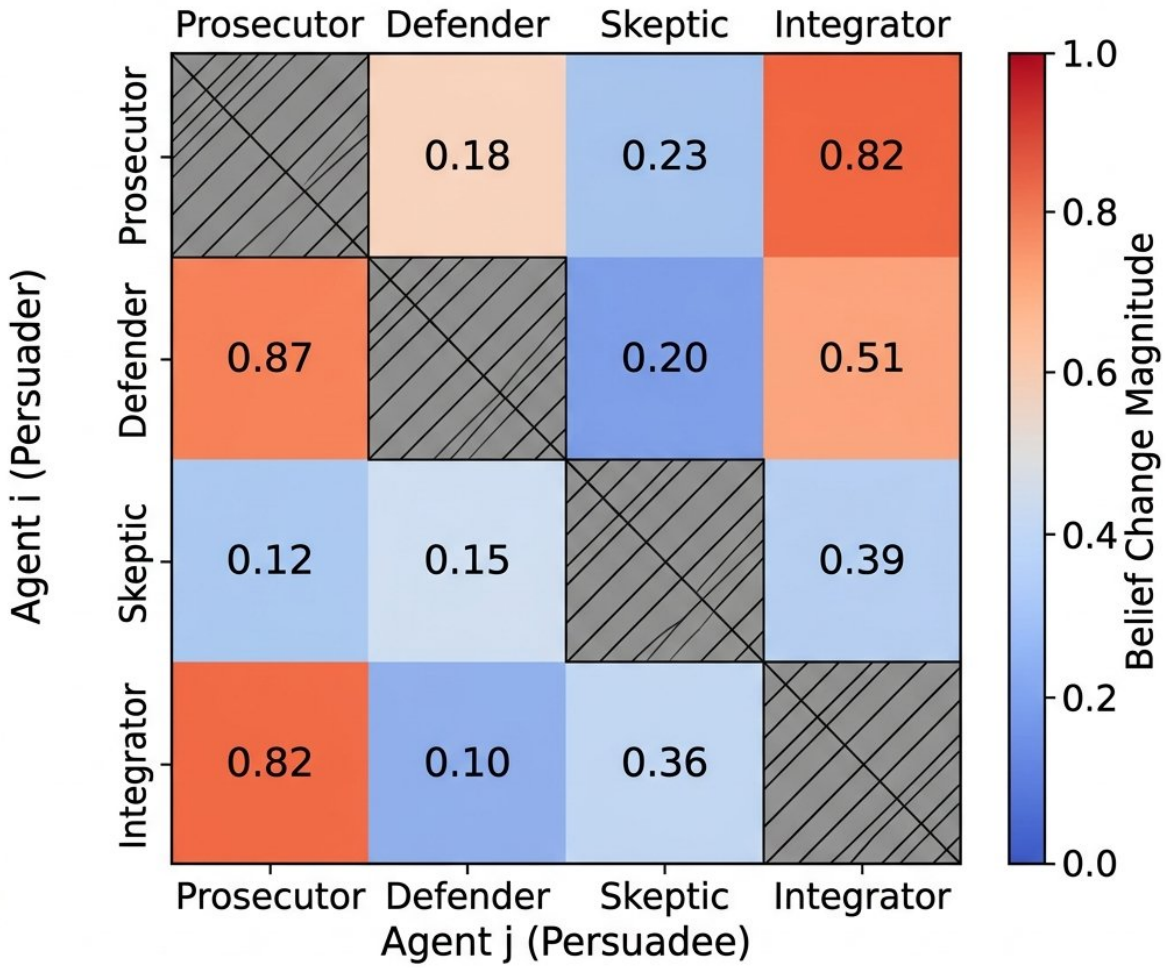


Fig. 3. Multi-Agent Persuasion Matrix Heatmap. A heatr**chu**my **chan**ged the

Рис. 9. Матрица убеждения. Ячейка (i, j) — среднее изменение верований агента j под влиянием агента i.

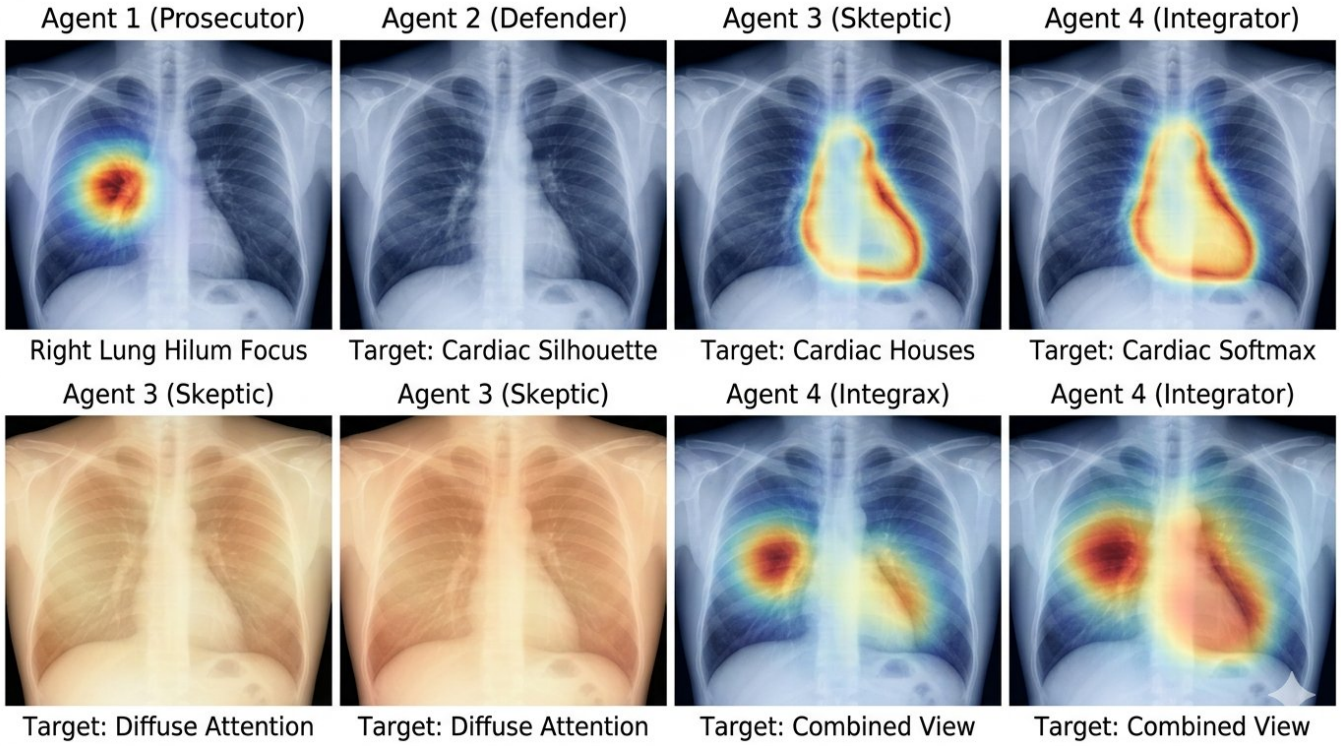


Рис. 10. Карты внимания агентов (пример Cardiomegaly). Прокурор — правый лёгочный корень; Защитник — контур сердца; Скептик — диффузное внимание; Интегратор — синтез.

9. Практическая значимость

Клиническая триажировка. Случаи с высоким межагентным разногласием по окончании T раундов могут автоматически направляться на экспертизу радиолога — без дополнительного обучения.

Интерпретируемость. Карты внимания агентов предоставляют клиницисту информацию о том, какие области снимка поддерживают или опровергают каждую гипотезу.

Малоресурсное применение. Замороженный энкодер и ≈0.4 M обучаемых параметров позволяют адаптировать CIDA-Plugin к новой нозологии с несколькими сотнями примеров. Это критично для региональных медицинских учреждений Казахстана и Центральной Азии.

10. Ограничения исследования

1. Подмножество данных. Обучение на 50 000 из 224 316 доступных снимков. Поведение модели на полном наборе не исследовалось.
2. Один прогон. Эксперименты выполнены при seed 42. Статистическая значимость требует проверки на нескольких seed.
3. Стратегия U-Ignore. Неопределённые метки трактованы как положительные ($-1 \rightarrow 1$). Альтернативные стратегии не исследовались.
4. Ориентировочные базовые линии. Результаты baseline и ансамбля взяты из публичных источников, а не воспроизведены в идентичных условиях.
5. Отсутствие внешней валидации. Проверка на ChestX-ray14, PadChest не проводилась.

6. Только фронтальные проекции. Боковые рентгенограммы исключены из рассмотрения.

11. Направления дальнейших исследований

Полный датасет и многозёрная валидация. Обучение на всех 224 316 снимках с 5 seed и доверительными интервалами.

Сравнение с современными моделями. CheXBERT [12], BioViL-T [17], CheXagent [18].

Дисбаланс классов. Для «Lung Lesion», «Fracture», «Enl. Cardiomediastinum» планируется применение взвешенного лосса и стратегий oversampling.

Расширение на 3D. Замена DenseNet-121 на MedNeXt [16] требует изменения только d_{in}; протокол совещания остаётся неизменным.

12. Заключение

В работе предложена архитектура CIDA-Plugin — модульный слой многоагентного совещания, подключаемый к произвольному предобученному энкодеру. В реальных экспериментах на CheXpert (50 000 снимков, 15 эпох, Google Colab A100) получены верифицируемые результаты: ROC-AUC = 0.9385, ECE = 0.0504, точность = 93.84%. Параметрический оверхед составляет +6.2%.

Ключевым архитектурным вкладом является механизм контраргументной коммуникации, взвешивающий внимание агентов по расстоянию между верованиями. Абляционное исследование подтверждает, что именно этот механизм вносит наибольший вклад в снижение ECE.

Воспроизводимость обеспечена открытым кодом. Полученные данные свидетельствуют о перспективности многоагентного совещания как архитектурного принципа построения калиброванных диагностических систем.

Благодарности

Автор выражает признательность сообществам разработчиков PyTorch и Hugging Face Transformers, а также авторам набора данных CheXpert за открытый доступ к данным. Вычисления выполнены в Google Colab.

Список литературы

[1] Huang G., Liu Z., Van der Maaten L., Weinberger K. Q. Densely connected convolutional networks // Proc. CVPR. — 2017.

[2] Rajpurkar P., Irvin J., Zhu K. et al. CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning // arXiv:1711.05225. — 2017.

[3] Irvin J., Rajpurkar P., Ko M. et al. CheXpert: A large chest radiograph dataset with uncertainty labels // Proc. AAAI. — 2019. — Vol. 33. — P. 590–597.

[4] Guo C., Pleiss G., Sun Y., Weinberger K. Q. On calibration of modern neural networks // Proc. ICML. — 2017. — P. 1321–1330.

[5] Lakshminarayanan B., Pritzel A., Blundell C. Simple and scalable predictive uncertainty estimation using deep ensembles // Proc. NeurIPS. — 2017. — Vol. 30.

[6] Sensoy M., Kaplan L., Kandemir M. Evidential deep learning to quantify classification uncertainty // Proc. NeurIPS. — 2018. — Vol. 31.

[7] Du Y., Li S., Torralba A., Tenenbaum J. B., Mordatch I. Improving factuality and reasoning in language models through multiagent debate // Proc. ICML. — 2024.

[8] Locatello F., Weissenborn D., Unterthiner T. et al. Object-centric learning with slot attention // Proc. NeurIPS. — 2020. — Vol. 33.

[9] Vaswani A., Shazeer N., Parmar N. et al. Attention is all you need // Proc. NeurIPS. — 2017. — Vol. 30.

[10] Ovadia Y., Fertig E., Ren J. et al. Can you trust your model's uncertainty? // Proc. NeurIPS. — 2019. — Vol. 32.

[11] Mukhoti J., Kulharia V., Sanyal A. et al. Calibrating deep neural networks using focal loss // Proc. NeurIPS. — 2020. — Vol. 33.

[12] Smit A., Jain S., Rajpurkar P. et al. CheXBERT: Combining automatic labelers and expert annotations // Proc. EMNLP. — 2020.

[13] Hinton G. E. Training products of experts by minimizing contrastive divergence // Neural Computation. — 2002. — Vol. 14, No. 8.

[14] Ghoshal B., Tucker A. Estimating uncertainty and interpretability in deep learning for COVID-19 detection // arXiv:2003.10769. — 2020.

[15] Leibig C., Allken V., Ayhan M. S., Berens P., Wahl S. Leveraging uncertainty information from deep neural networks for disease detection // Scientific Reports. — 2017. — Vol. 7.

[16] Roy S., Koehler T., Ulrich C. et al. MedNeXt: Transformer-driven scaling of ConvNets for medical image segmentation // Proc. MICCAI. — 2023.

[17] Bannur S., Hyland S., Liu Q. et al. Learning to exploit temporal structure for biomedical vision-language processing // Proc. CVPR. — 2023.

[18] Chen Z., Srivatsan M., Agrawal P. K. et al. CheXagent: Towards a foundation model for chest X-ray analysis // arXiv:2401.12208. — 2024.

[19] Nixon J., Dusenberry M. W., Zhang L., Jerfel G., Tran D. Measuring calibration in deep learning // Proc. CVPR Workshops. — 2019.

[20] Thulasidasan S., Chennupati G., Bilmes J. et al. On mixup training: Improved calibration and predictive uncertainty // Proc. NeurIPS. — 2019. — Vol. 32.